


Rapport d'évaluation - Analyse de sentiments

Deux modèles de régression logistique sont évalués : un modèle 'positif' et un modèle 'négatif'. Les matrices de confusion et les métriques (précision, rappel, F1-score) sont présentées ci-dessous.


Modèle positif

	precision	recall	f1-score	support
0	0.73	1.00	0.84	8
1	1.00	0.40	0.57	5
accuracy			0.77	13
macro avg	0.86	0.70	0.71	13
weighted avg	0.83	0.77	0.74	13



Modèle négatif

	precision	recall	f1-score	support
0	0.60	0.86	0.71	7
1	0.67	0.33	0.44	6
accuracy			0.62	13
macro avg	0.63	0.60	0.58	13
weighted avg	0.63	0.62	0.59	13



Observations : erreurs fréquentes et biais

Les deux modèles s'appuient sur un corpus d'amorçage réduit (50 tweets), ce qui limite la robustesse des estimations. Les matrices de confusion montrent un rappel plus faible sur la classe minoritaire (tweets explicitement positifs ou négatifs) : le modèle a tendance à classer les tweets dans la classe majoritaire (0), d'où des faux négatifs. Ce biais s'explique par le déséquilibre des classes et la faible taille du jeu de données. La vectorisation Bag-of-Words ignore par ailleurs la négation (« pas bien ») et le contexte, source d'erreurs sur les tournures ironiques ou nuancées.

Recommandations pour améliorer le modèle

1. Augmenter la taille et la diversité du corpus annoté (plusieurs milliers de tweets) pour réduire la variance.
2. Rééquilibrer les classes (sur-échantillonnage, `class_weight`) et surveiller le F1-score plutôt que l'exactitude.
3. Remplacer le Bag-of-Words par des n-grammes ou du TF-IDF, voire des embeddings (word2vec, FastText) pour capturer le contexte et la négation.
4. Ajuster les hyperparamètres (régularisation C) par validation croisée.
5. Mettre en place le réentraînement périodique (`scripts/retrain.py`) sur les données fraîches collectées via l'API.